



# Υψηλού επιπέδου υλοποίηση των αλγορίθμων Hierarchical Temporal Memory σε Julia


---

Κωνσταντίνος Σαμαράς-Τσακίρης  
Επιβλέπων καθηγητής: Νίκος Πιτσιάνης  
13 Ιουνίου 2019


# Νευρώνας




# Μικροστήλες




# Φλοιικές στήλες




# Αναστολή μεταξύ μικροστηλών




# Χωρικός συγκεντρωτής





## Βήματα

0. Αντιστοίχιση χώρων εισόδου/εξόδου, αρχικοποίηση εγγύς συνάψεων
1. Επικάλυψη μικροστηλών με συνδεδεμένες εξόδους
2. Παρώθηση
3. Τοπική αναστολή
4. Ενεργοποίηση μικροστηλών που νίκησαν
5. Εκμάθηση συνάψεων ενεργών μικροστηλών



## Βήματα

0. Αντιστοίχιση χώρων εισόδου/εξόδου, αρχικοποίηση εγγύς συνάψεων
1. Επικάλυψη μικροστηλών με συνδεδεμένες εξόδους
2. Παρώθηση
3. Τοπική αναστολή
4. Ενεργοποίηση μικροστηλών που νίκησαν
5. Εκμάθηση συνάψεων ενεργών μικροστηλών



# Στοιχεία Χωρικού Συγκεντρωτή

---

## Αντιστοίχιση εισόδου/εξόδου: υπερκύβος

Δείκτης υπερκύβου

$$I(x_j; x_i^c, \gamma) = \textit{true} \iff x_j \in \text{hypercube}$$

$x^c$  κέντρο υπερκύβου

$\gamma$  ακτίνα υπερκύβου

# Αντιστοίχιση εισόδου/εξόδου: υπερκύβος

## Δείκτης υπερκύβου

$$I(x_j; x_i^c, \gamma) = \text{true} \iff x_j \in \text{hypercube}$$

$x^c$  κέντρο υπερκύβου

$\gamma$  ακτίνα υπερκύβου

```
struct Hypercube{N}
  xc::NTuple{N,Int}
  γ::Int
  sz::NTuple{N,Int}
  indices::CartesianIndices{N}
end
Hypercube(xc,γ,sz)= Hypercube(xc,γ,sz, start(xc,γ,sz))
start(xc,γ,sz)= CartesianIndices(map( (a,b)-> a:b,
                                     max.(xc .- γ, 1), min.(xc .+ γ, sz) ))
Base.collect(hc::Hypercube)= map(c->c.I, collect(hc.indices))

jl> collect(Hypercube((1,1),1,(5,5)))
2x2 Array{Tuple{Int64,Int64},2}:
 (1, 1) (1, 2)
 (2, 1) (2, 2)
```

Εν δυνάμει συνδέσεις

$$\Pi_i = \{j \mid I(x_j; x_i^c, \gamma) \wedge Z_{ij} < p\}$$

όπου  $Z \in U(0, 1)$  τυχαίος αριθμός

# Αρχικοποίηση συνάψεων

Εν δυνάμει συνδέσεις

$$\Pi_i = \{j \mid I(x_j; x_i^c, \gamma) \wedge Z_{ij} < p\}$$


όπου  $Z \in U(0, 1)$  τυχαίος αριθμός

```
c2lin = LinearIndices(szin)
c2lsp = LinearIndices(szsp)

Dp = zeros($q, prod(szin), prod(szsp))
foreach(out_lattice()) do yi
    # Linear indices from hypercube
    x = @>> yi xc xi collect map(x->c2lin[x...])
    Dp[x, c2lsp[yi...]] = permanences(@> yi xc xi)
end

@> yi xc xi == xi(xc(yi))
```

# Αρχικοποίηση συνάψεων



Επικάλυψη μικροστηλών με συνδεδεμένες εισόδους

$$\mathbf{W} = \mathbf{D} \geq \theta_c$$

$$o = b \mathbf{W} z$$

$\mathbf{W}$   $[\ell_{in} \times \ell_{sp}]$  συνδεδεμένες συνάψεις

$z$   $[\ell_{in}]$  είσοδος

$b$   $[\ell_{sp}]$  παρώθηση

Επικάλυψη μικροστηλών με συνδεδεμένες εισόδους

$$\mathbf{W} = \mathbf{D} \geq \theta_c$$

$$o = b \mathbf{W} z$$

$\mathbf{W}$  [ $\ell_{in} \times \ell_{sp}$ ] συνδεδεμένες συνάψεις

$z$  [ $\ell_{in}$ ] είσοδος

$b$  [ $\ell_{sp}$ ] παρώθηση

```
Wp()= Dp .>= theta_permanence  
o(z)= @> (b() .* Wp()'z) reshape(sz_sp)
```



# Επικάλυψη

Επικάλυψη μικροστηλών με συνδεδεμένες εισόδους

$$\mathbf{W} = \mathbf{D} \geq \theta_c$$

$$o = b \mathbf{W} z$$

$\mathbf{W}$  [ $\ell_{in} \times \ell_{sp}$ ] συνδεδεμένες συνάψεις

$z$  [ $\ell_{in}$ ] είσοδος

$b$  [ $\ell_{sp}$ ] παρώθηση

```
Wp()= Dp .>= theta_permanence  
o(z)= @> (b() .* Wp()'z) reshape(sz_sp)
```

broadcasting

```
f(x::Int)= x+1;  
jl> f.([1; 10; 100])  
3-element Array{Int64,1}:  
 2  
11  
101
```

Κανόνας πλαστικότητας

$$\Delta \mathbf{D} = p^+(z \circ \mathbf{D} \circ c) - p^-(\neg z \circ \mathbf{D} \circ c)$$

$c$  ενεργοποίηση χωρικού συγκεντρωτή

Κανόνας πλαστικότητας

$$\Delta \mathbf{D} = p^+(z \circ \mathbf{D} \circ c) - p^-(\neg z \circ \mathbf{D} \circ c)$$

$c$  ενεργοποίηση χωρικού συγκεντρωτή

Απλούστερος τρόπος

```
learn!(D_p,z,a)= begin
    D_p[z,a]  .+= (D_p[z,a].>0) .* (D_p[z,a]  .⊕ p+)
    D_p[.!z,a].+= (D_p[z,a].>0) .* (D_p[.!z,a] .⊖ p-)
end
```

Κανόνας πλαστικότητας

$$\Delta \mathbf{D} = p^+(z \circ \mathbf{D} \circ c) - p^-(\neg z \circ \mathbf{D} \circ c)$$

$c$  ενεργοποίηση χωρικού συγκεντρωτή


Καλύτερα

```
learn!(Dp,z,a)= begin
  Dpactive= @view Dp[:,a] # the only elements we touch
  activeConn= (Dpactive .> 0) .& z
  inactiveConn= (Dpactive .> 0) .& .!z
  Dpactive.= activeConn .* (Dpactive .⊕ p+) .+
              inactiveConn .* (Dpactive .⊖ p-)
end
```

## Χρονική μνήμη

---

# Αναστολή εντός μικροστηλών




# Μνήμη ακολουθιών

## A Cellular layers learn sequences




## B Before learning




Same columns,  
but only one cell active per  
column.

## C After learning




# Μνήμη ακολουθιών

## A Prediction of next input



## B Multiple simultaneous predictions



## Βήματα

1. Ενεργοποίηση
2. Προσδοκία/πρόβλεψη
3. Εκμάθηση συνάψεων ενεργών νευρώνων

## Μεταβλητές κατάστασης

$D_d \in \mathbb{S}^{N_n \times N_s}$ : πίνακας  
συναπτικών μονιμοτήτων


$NS \in \mathbb{B}^{N_n \times N_s}$ : πίνακας  
γειννίας νευρώνων -  
δενδριτών

$SC \in \mathbb{B}^{N_s \times N_c}$ : πίνακας  
γειννίας δενδριτών -  
μικροστηλών




# Μνήμη ακολουθιών

## A Prediction of next input



## B Multiple simultaneous predictions



## Βήματα

1. Ενεργοποίηση
2. Προσδοκία/πρόβλεψη
3. Εκμάθηση συνάψεων ενεργών νευρώνων

## Μεταβλητές κατάστασης

$D_d \in \mathbb{S}q^{N_n \times N_s}$ : πίνακας  
συναπτικών μονιμοτήτων

$NS \in \mathbb{B}^{N_n \times N_s}$ : πίνακας  
γεινίασης νευρώνων -  
δενδριτών

$SC \in \mathbb{B}^{N_s \times N_c}$ : πίνακας  
γεινίασης δενδριτών -  
μικροστηλών

# Ενεργοποίηση χρονικής μνήμης

## Ενεργοποίηση

$$\alpha_{ij} = \begin{cases} 1, & j \in c \wedge \pi_{ij}^{t-1} = 1 \text{ (πρόβλεψη)} \\ 1, & j \in c \wedge \sum_i \pi_{ij}^{t-1} = 0 \text{ (έξαρση)} \\ 0, & \text{αλλιώς} \end{cases} \quad (1)$$

$c$  ενεργές μικροστήλες

$\pi_{ij}$  προβλεπτικοί νευρώνες,  $j$ : μικροστήλη,  $i$ : νευρώνας στη  $j$


```
burst(c,Π)= c .& .!@percolumn(any,Π, k)
predicted(c,Π)= @percolumn(&,Π,c, k)
activate(c,Π)= (predicted(c,Π) .| burst(c,Π)')|> vec
```



## Πείραμα πρόβλεψης χρονοσειράς

---





Σχήμα 2: Ωριαία κατανάλωση ισχύος σε γυμναστήριο



# Βιβλιογραφία

---



# Αναφορές

---



S. Billaudelle και S. Ahmad, «Porting HTM Models to the Heidelberg Neuromorphic Computing Platform», 8 Μάι. 2015. arXiv: 1505.02142 [cs, q-bio]. Διεύθυν.: <http://arxiv.org/abs/1505.02142> (επίσκεψη 02/06/2019).



Y. Cui, S. Ahmad και J. Hawkins, «Continuous Online Sequence Learning with an Unsupervised Neural Network Model,» **Neural Computation**, τόμ. 28, αρθμ. 11, σσ. 2474–2504, 14 Σεπτ. 2016, ISSN: 0899-7667. DOI: 10.1162/NECO\_a\_00893.



J. Hawkins και S. Ahmad, «Why Neurons Have Thousands of Synapses, a Theory of Sequence Memory in Neocortex,» **Frontiers in Neural Circuits**, τόμ. 10, 2016, ISSN: 1662-5110. DOI: 10.3389/fncir.2016.00023.



Y. Cui, S. Ahmad και J. Hawkins, «The HTM Spatial Pooler—A Neocortical Algorithm for Online Sparse Distributed Coding,» **Frontiers in Computational Neuroscience**, τόμ. 11, 2017, ISSN: 1662-5188. DOI: 10.3389/fncom.2017.00111.



J. Hawkins, S. Ahmad και Y. Cui, «A Theory of How Columns in the Neocortex Enable Learning the Structure of the World,» *Frontiers in Neural Circuits*, τόμ. 11, 2017, ISSN: 1662-5110. DOI: 10.3389/fncir.2017.00081.



Fabuio. (2017-07-06), Pyramidal neuron, διεύθυν.: [https://upload.wikimedia.org/wikipedia/commons/c/c1/Pyramidal\\_cell.svg](https://upload.wikimedia.org/wikipedia/commons/c/c1/Pyramidal_cell.svg) (επίσκεψη 31/05/2019).